

ЛЕКЦИЯ 11

Навигация и ориентация в недетерминированной среде

*Сенсоры, вероятностная локализация, SLAM и мультиробот-картографирование,
планирование и координация*

две части по 45

«...ение распределёнными робототехническими системами»

План лекции

1

Три задачи навигации и четыре источника неопределённости

2

Сенсоры: лидар, камера, IMU, одометрия, GNSS, УВБ

3

Комплексирование данных: системы координат и время

4

Байесовский фильтр, фильтр Калмана, EKF

5

Разбор численного примера шага фильтра

6

Фильтр частиц, MCL и постановка задачи SLAM

7

Мультиробот-SLAM: межроботные замыкания и распределённая оптимизация

8

Планирование пути: A*, PRM/RRT*, потенциальные поля

9

Избегание столкновений в группе: VO, RVO, ORCA

10

Формации, согласование и POMDP

Синие — первая часть · янтарные — вторая часть

ЧАСТЬ 1

Часть 1. Восприятие, комплексирование и вероятностная локализация

От физики сенсоров к байесовскому фильтру и его практическим реализациям.

1 Навигация: три задачи и четыре источника шума

- Локализация — «где я?», картографирование — «как выглядит мир?», планирование — «как доехать?»
- Шум измерений: сенсор врёт на случайную величину
- Неопределённость действия: «проехать метр» выполняется приблизительно
- Динамика среды: препятствия появляются, люди и роботы движутся
- В PPTC добавляется неопределённость связи: задержки, потери, смена топологии

Ключевая идея

В детерминированной среде все три задачи имеют точные решения. Вся сложность реальной навигации возникает именно из недетерминированности — и требует другого математического языка.

“

Состояние робота принципиально нельзя знать точно. Вместо числа мы оцениваем распределение — доверительное состояние $\text{bel}(x_t) = p(x_t \mid z_{1:t}, u_{1:t})$.

Основной постулат вероятностной робототехники (Thrun, Burgard, Fox)

Специфика распределённых систем

- Сосед — источник данных: взаимные наблюдения уточняют позы обоих
- Сосед — динамическое препятствие, причём принимающее решения
- Локальные карты роботов заданы в разных системах координат
- Ошибки оценок агентов коррелированы — простое усреднение недопустимо
- Полоса связи ограничена: сырые сканы передавать нечем


- Проприоцептивные: энкодеры, гироскопы, акселерометры — внутреннее состояние
- Экстероцептивные: лидар, камера, радар, GNSS — внешняя среда
- Активные излучают энергию (лидар, сонар, радар), пассивные только принимают
- Проприоцептивные дрейфуют, экстероцептивные зависят от условий наблюдения
- Вывод: самодостаточного сенсора не существует, нужна связка

Лидар


- $r = c \cdot \Delta t / 2$ — дальность по времени пролёта
- Точность единицы сантиметров, метрика сразу
- Не зависит от освещённости
- Дорог, тяжёл, боится осадков и стекла
- Основа сеточного SLAM и scan matching

Камера

- Стереоскоп: глубина $Z = f \cdot b / d$, ошибка растёт квадратично
- Богатая семантика: знаки, люди, текстура
- Дёшево и легко — годится для БПЛА
- Слабая текстура и плохой свет ломают оценку
- Основа визуальной одометрии и ORB-SLAM



© R. Siegwart, ETH Zurich - ASL



Note: the first and still most prominent example of a GNSS (Global Navigation


Созвездие спутников GPS и сеть наземных станций слежения; первый и наиболее известный пример GNSS.

- IMU: гироскопы ω , акселерометры a , часто магнитометр; сотни герц
- Интегрирование ускорений — ошибка позиции растёт квадратично со временем
- Одометрия дифпривода: $\Delta s = R(\Delta\phi_r + \Delta\phi_l)/2$, $\Delta\theta = R(\Delta\phi_r - \Delta\phi_l)/L$
- Проскальзывание и неточная колея дают систематическую ошибку
- Оба источника автономны и быстры, но обязаны корректироваться извне

Факт

Свободный дрейф недорогого MEMS-IMU уводит оценку положения на десятки метров за минуту полёта. Без корректирующего источника инерциальная навигация бесполезна уже на масштабе задачи робота.

2 Поза дифференциального привода и матрица $R(\theta)$



Поза робота ξ в инерциальной (глобальной) и связанной (локальной) системах координат; ортогональная матрица поворота $R(\theta)$ связывает их.

? Как думаете?

Робот десять минут ездит по цеху, используя только энкодеры и IMU. Что произойдёт с его оценкой положения?

A Ошибка останется в пределах шума датчиков

B Ошибка будет расти, но ограниченно — усреднится

C Ошибка будет неограниченно накапливаться

D Ошибка зависит только от качества IMU

Ответ: Верно третье: интегрирование шума даёт случайное блуждание, ошибка растёт неограниченно, и никакое качество датчика этого не отменяет — только замедляет.

- Сверхширокополосные метки: точность дальности 10–30 см в помещении
- Позиция находится мультилатерацией по нескольким якорям
- Ключевое для RRTC: УВБ меряет расстояния между самими роботами
- Радар даёт дальность и радиальную скорость по Доплеру, устойчив к осадкам
- Радионавигация не дрейфует, но страдает от многолучёвости

Сенсор	Что даёт	Слабое место	Характер ошибки
Лидар	Геометрия сцены, дальности	Цена, масса, осадки, стекло	Ограниченная
Камера	Текстура, семантика, признаки	Свет, слабая текстура	Ограниченная, но с масштабом
IMU	Ускорения и угловые скорости	Дрейф смещения нуля	Накапливается квадратично
Одометрия	Приращения пути и курса	Проскальзывание колёс	Накапливается
GNSS	Абсолютные координаты	Нет в помещении, выбросы	Ограниченная
УВБ	Дальности до якорей и роботов	Нужна инфраструктура	Ограниченная

Правый столбец — главный: сенсоры делятся на «дрейфующие» и «не дрейфующие», и комплексование строится именно на этой паре.

- Каждый сенсор меряет в своей системе координат — нужна калибровка
- Однородные матрицы 4×4 объединяют поворот и перенос
- Ориентация в 3D — кватернионы $q = (w, x, y, z)$, без складывания рамок
- Временная синхронизация: единая шкала и учёт задержек обработки
- Ошибка синхронизации в 50 мс при 1 м/с — это 5 см систематики

Пример

Классический баг: лидар и IMU не синхронизированы по времени, и на поворотах карта «размазывается». Пока не поправлена временная метка, никакая математика фильтра положение не спасёт.



Все алгоритмы локализации — конкретные реализации этих двух шагов, различающиеся представлением bel .

$$K_k = P_k^- \cdot H^T \cdot (H \cdot P_k^- \cdot H^T + R)^{-1}$$

- P_k^- — ковариация прогноза, R — ковариация шума измерения
- $R \rightarrow 0$: K растёт, оценка почти целиком доверяет измерению
- $P_k^- \rightarrow 0$: $K \rightarrow 0$, прогноз точен и коррекция почти не нужна
- $\hat{x}_k = \hat{x}_k^- + K_k \cdot (z_k - H \cdot \hat{x}_k^-)$ — коррекция пропорциональна инновации

Фильтр Калмана оптимален по среднеквадратичной ошибке для линейной гауссовской системы.

Один такт фильтра в цифрах

$0,29 \text{ м}^2$

дисперсия после прогноза (была $0,25$ — движение добавило шум)

$0,763$

усиление Калмана K при $R = 0,09 \text{ м}^2$

$0,069 \text{ м}^2$

дисперсия после коррекции — меньше и прогноза, и измерения

- Оценка $3,19 \text{ м}$ лежит между прогнозом $3,0 \text{ м}$ и измерением $3,25 \text{ м}$
- Ближе к измерению, потому что в этом такте оно точнее прогноза

- Реальные модели нелинейны: $x += v \cdot \Delta t \cdot \cos \theta$, $r = \sqrt{(m_x - x)^2 + (m_y - y)^2}$
- ЕКФ раскладывает $g(\cdot)$ и $h(\cdot)$ в ряд Тейлора первого порядка
- Матрицы A и H заменяются якобианами $G_k = \partial g / \partial x$ и $H_k = \partial h / \partial x$
- При большой неопределённости линеаризация неверна — фильтр расходится
- ЕКФ унимодален: одна гауссиана, несколько гипотез не удержать
- UKF обходится без якобианов через сигма-точки, но унимодальность остаётся

Алгоритм расширенного фильтра Калмана

Extended Kalman Filter Algorithm

System equation: $\hat{\mathbf{x}}_t = f(\mathbf{x}_{t-1}, \mathbf{u}_t) + \boldsymbol{\varepsilon}_t$

Measurement equation: $\mathbf{z}_t = h(\hat{\mathbf{x}}_t) + \boldsymbol{\delta}_t$

Linearization via first order
Taylor series expansion!

Relevant Jacobians:

$$F_t(\mathbf{x}_{t-1}, \mathbf{u}_t) = \frac{\partial f(\mathbf{x}_{t-1}, \mathbf{u}_t)}{\partial \mathbf{x}_{t-1}}$$

(see s. 18-20 for computing)

$$H_t(\hat{\mathbf{x}}_t) = \frac{\partial h(\hat{\mathbf{x}}_t)}{\partial \mathbf{x}_t}$$

Algorithm EKF ($\mathbf{x}_{t-1}, \Sigma_{t-1}, \mathbf{u}_t, \mathbf{z}_t$)

Prediction

1. $\hat{\mathbf{x}}_t = f(\mathbf{x}_{t-1}, \mathbf{u}_t)$
2. $\hat{\Sigma}_t = F_t \Sigma_{t-1} F_t^T + R_t$



Correction or update

3. $K_t = \hat{\Sigma}_t H_t^T (H_t \hat{\Sigma}_t H_t^T + Q_t)^{-1}$
4. $\mathbf{x}_t = \hat{\mathbf{x}}_t + K_t (\mathbf{z}_t - h(\hat{\mathbf{x}}_t))$
5. $\Sigma_t = (I - K_t H_t) \hat{\Sigma}_t$
6. **Return** $\mathbf{x}_t, \Sigma_t$

[Adapted from Thrun et al., 2005]

2.1

EKF: системное и измерительное уравнения, якобианы F_t и H_t , шаги прогноза и коррекции; линейризация через ряд Тейлора первого порядка.



Пример оценки траектории (x , y) и курса при слиянии одометрии по энкодерам с GPS в высокоточной симуляции.

П Е Р Е Р Ы В

Конец первой части

Разобрали сенсоры, комплексирование и вероятностную локализацию вплоть до EKF. После перерыва — SLAM, мультиробот-картографирование, планирование пути и координация группы.


ЧАСТЬ 2

Часть 2. SLAM, распределённое картографирование и движение

Строим карту без карты, объединяем карты группы, планируем путь и расходимся без столкновений.

3

Фильтр частиц: три операции такта



MCL — применение фильтра частиц к локализации по карте: решает и сопровождение позы, и глобальную локализацию, и «похищенного робота».

Критерий	KF / EKF	UKF	Фильтр частиц (MCL)
Представление belief	Гауссиана ($\hat{x}$, P)	Сигма-точки	Взвешенные частицы
Нелинейности	Линеаризация, якобианы	Без якобианов, точнее	Любые модели
Многомодальность	Нет	Нет	Да
Глобальная локализация	Нет	Нет	Да
Стоимость	Низкая, $O(n^2)$ – $O(n^3)$	Умеренная	Высокая, растёт с M
Типичная роль	Слияние IMU/GNSS/одометрии	Сильные нелинейности	Локализация по карте

Практика: EKF на быстром контуре комплексирования и MCL на медленном контуре локализации по карте прекрасно уживаются в одном стеке.

SLAM: замкнутый круг и как из него выйти

- Чтобы строить карту, нужна поза; чтобы знать позу, нужна карта
- Онлайн-SLAM оценивает $p(x_t, m \mid z, u)$, полный SLAM — всю траекторию $p(x_{1:t}, m \mid z, u)$
- Ошибки позы и карты коррелированы: смещённая поза даёт смещённые ориентиры
- Ассоциация данных — сопоставление наблюдения с элементом карты
- Карты: признаковые (координаты ориентиров) и сеточные (occupancy grid)

Ключевая идея

Замыкание цикла — распознавание ранее посещённого места — даёт ограничение, которое «стягивает» всю накопленную по траектории ошибку одним махом.

? Как думаете?

Робот ошибочно решил, что видит ранее посещённый угол здания, хотя это другой похожий угол. Что произойдёт с картой?

A Ничего, одно ребро среди тысяч утонет в шуме

B Карта локально исказится возле этого места

C Оптимизация может исказить карту целиком

D Фильтр отбросит это ребро автоматически

Ответ: Верно третье: ложное замыкание — жёсткое ограничение с высокой информативностью, оптимизация «сложит» две разные части карты вместе и разрушит всю геометрию.

ЕКФ-SLAM

- Состояние: поза плюс координаты всех ориентиров
- P хранит все взаимные корреляции
- Коррекция стоит $O(n^2)$ по числу ориентиров
- Сотни признаков — предел применимости
- Одна ошибка ассоциации рушит оценку

Графовый SLAM

- Вершины — позы и ориентиры, рёбра — ограничения
- Разреженность даёт почти линейную сложность
- Фронтенд строит граф, бэкенд оптимизирует
- Библиотеки g2o, GTSAM, Ceres; iSAM2 — инкрементально
- Современный стандарт для полного SLAM

$$\mathbf{x}^* = \operatorname{argmin} \sum \langle i, j \rangle \mathbf{e}_{ij}^T \cdot \Omega_{ij} \cdot \mathbf{e}_{ij}$$

- $\mathbf{e}_{ij}$ — невязка между измеренным и предсказанным относительным положением
- Ω_{ij} — информационная матрица ребра, обратная ковариации: вес доверия
- Решается Гауссом–Ньютоном или Левенбергом–Марквардтом по разреженной алгебре
- Рёбра: одометрия, наблюдения ориентиров, замыкания циклов

Задача огромная по размерности, но разреженная — поэтому решается за время, близкое к линейному.

- Rao–Блэквеллизация: при известной траектории ориентиры условно независимы
- Траектория — фильтром частиц, каждый ориентир — своим EKF 2×2
- Сложность $O(M \cdot \log n)$, устойчивость к ошибкам ассоциации
- GMapping — стандарт сеточного лидарного SLAM в ROS
- ORB-SLAM — графовая визуальная система: моно, стерео, RGB-D

4 Кооперативная локализация и «инцест данных»

- Взаимное измерение $z^{AB} = h(x^A, x^B) + v$ связывает позы двух роботов
- Централизованный EKF по группе оптимален, но не масштабируется
- После первого обмена оценки роботов становятся коррелированными
- Повторный учёт той же информации занижает ковариацию — фильтр «самоуверен»
- Ковариационное пересечение: $P^{-1} = \omega \cdot P_a^{-1} + (1-\omega) \cdot P_b^{-1}$, состоятельно без знания корреляций

Кейс

Один робот группы выехал на открытое место и поймал GNSS. Через цепочку взаимных наблюдений его абсолютная привязка «просачивается» ко всем остальным, включая тех, кто спутников не видит.

5 Мультиробот-SLAM: почему это не «SLAM, только больше»


- Межроботная ассоциация данных: сопоставить наблюдения роботов, не видевших друг друга
- Неизвестны относительные преобразования между системами координат агентов
- Ложные совпадения мест между роботами гораздо вероятнее внутрироботных
- Похожие коридоры и типовые помещения — фабрика ложных совпадений
- Полоса связи ограничена: сырые сканы и облака точек передавать нечем

Ключевая идея

Одиночный SLAM ошибается во времени — вдоль своей траектории. Мультиробот-SLAM ошибается ещё и в пространстве агентов, где нет ни общей системы координат, ни надёжного канала для проверки гипотез.

5

Конвейер распределённого мультиробот-SLAM



Каждый шаг конвейера ограничен полосой связи — поэтому передаются подписи и оценки, а не данные.

5 Распределённая оптимизация графа поз = расщепление плюс консенсус

- Общий граф группы расщепляется на подграфы: у каждого робота свои вершины
- Пограничные вершины дублируются, для них требуется согласие соседей
- Обмениваются только оценки пограничных переменных, а не рёбра и сканы
- Схемы: распределённый Гаусс–Зайдель, ADMM, распределённый градиентный спуск
- Сходимость зависит от связности графа связи — знакомый нам $\lambda_2(L) > 0$

Ключевая идея

Это ровно тот же приём, что и в распределённой оптимизации из предыдущих лекций: расщепить общую задачу по агентам и склеить решения условием консенсуса на пересечении.

Отбраковка выбросов: критический этап

- Одно ложное межроботное совпадение способно разрушить всю объединённую карту
- Идея проверки: истинные ограничения попарно согласованы, ложные — нет
- Максимальная клика взаимно согласованных измерений (PCM) отбирает надёжное ядро
- Робастные ядра и градуированная невыпуклость (GNC) гасят вес подозрительных рёбер
- Отбраковка выполняется до оптимизации, а не после — потом уже поздно

Факт

Внутри одного робота гипотезу замыкания можно проверить по своей же траектории. Между роботами такой проверки нет — поэтому робастность здесь не опция, а условие работоспособности.

Kimera-Multi

- Плотный метрико-семантический распределённый SLAM
- Строит 3D-меш с семантическими метками
- Распределённая оптимизация поз с робастной отбраковкой
- Проверено на реальных группах в полевых экспериментах
- Требователен к вычислениям на борту

Swarm-SLAM

- Разреженный децентрализованный каркас на ROS 2
- Сделан под ограниченный канал и большие рои
- Обмен компактными дескрипторами мест
- Модульность: лидар, стерео, RGB-D фронтенды
- Акцент на экономию трафика и энергии


“

В мультиробот-SLAM канал связи — такой же ресурс проектирования, как процессор и батарея. Сначала считаем бюджет байтов, потом выбираем алгоритм.

Практическое правило распределённого картографирования

6

A*: как работает поиск с эвристикой



Допустимая эвристика (не завышает истинную стоимость) гарантирует оптимальность; при $h = 0$ A* вырождается в Дейкстру.

PRM — дорожная карта

- Случайные точки в C_{free} соединяются в граф
- Строится один раз, отвечает на много запросов
- Хорошо для статики и манипуляторов
- После построения — обычный поиск A*
- Плохо переносит изменения среды

RRT / RRT*

- Дерево растёт от старта к случайным точкам
- Рост смещён в неисследованные области
- Легко учитывает динамику: интегрируем управления
- RRT — путь неоптимален, нужно сглаживание
- RRT* добавляет rewiring: асимптотическая оптимальность

Потенциальные поля: простота и её ловушка

- Цель притягивает, препятствия отталкивают: $U(q) = U_{\text{att}}(q) + U_{\text{rep}}(q)$
- $F_{\text{att}} = -k_{\text{att}} \cdot (q - q_{\text{goal}})$, отталкивание действует лишь в радиусе ρ_0
- Вычислительно почти бесплатно, работает прямо по сырым сенсорным данным
- Локальные минимумы: перед вогнутым препятствием робот застревает
- Осцилляции в узких коридорах — вторая типовая болезнь метода

Пример

Робот перед П-образным препятствием: притяжение к цели и отталкивание от стенок уравниваются, суммарная сила нулевая — робот стоит и «думает», что всё в порядке.

Метод	Оптимальность	Динамическая среда	Роль в стеке
A*	Оптimalен при допустимой h	Полный перезапуск	Глобальный планировщик
D* Lite	Оптimalен	Эффективный перерасчёт	Глобальный, неизвестная среда
PRM	Асимптотически (PRM*)	Слабо	Статика, манипуляторы
RRT / RRT*	RRT — нет, RRT* — асимптотически	Средне	БПЛА, кинодинамика
Потенциальные поля	Нет, локальные минимумы	Отлично	Реактивный слой
TEB	Локально оптimalен	Отлично	Локальный планировщик

Реальный стек всегда двухуровневый: медленный глобальный планировщик по карте плюс быстрый локальный по свежим данным.



Как думаете?

Два робота едут навстречу и оба уклоняются вправо по методу препятствий по скорости (VO). Что наблюдается на практике?

A

Оба спокойно разъезжаются

B

Возникают осцилляции: манёвр — отмена — манёвр

C

Роботы столкнутся: VO этого не ловит

D

Один остановится, другой проедет

Ответ: Верно второе: каждый считает, что сосед скорость не изменит; оба уклонились, стало безопасно, оба вернулись к прежней скорости — и цикл повторяется.

- VO — конус скоростей, ведущих к столкновению при неизменных скоростях соседа
- RVO: каждый берёт на себя половину манёвра — осцилляции исчезают
- ORCA строит для каждого соседа полуплоскость допустимых скоростей
- Пересечение полуплоскостей — выпуклое множество; выбор скорости это малое ЛП
- Децентрализован, связи не требует, масштабируется на тысячи агентов
- Базовая формулировка голономна; для дифпривода есть NH-ORCA

- Лидер — последователь: $u_i = k_p \cdot (p_{\text{leader}} + d_i - p_i) + k_v \cdot (v_{\text{leader}} - v_i)$
- Просто и наглядно, но лидер — единая точка отказа
- Распределённые схемы задают формацию через расстояния между соседями
- Консенсус: $x_i(t+1) = x_i(t) + \sum_j a_{ij} \cdot (x_j(t) - x_i(t))$ сходится при связности во времени
- Правила Рейнольдса: разделение, выравнивание, сплочение — рой без центра

Ключевая идея

Скорость сходимости согласования определяется алгебраической связностью $\lambda_2(L)$: топология сети — это параметр управления, а не внешнее обстоятельство.

- MDP: политика $\pi(s)$ из уравнения Беллмана — универсальный план для всех состояний
- POMDP: политика отображает в действия не состояния, а доверительные состояния b
- Автоматически возникает активное восприятие: подъехать к ориентиру и уточнить позу
- Точное решение неразрешимо: пространство b непрерывно и высокоразмерно
- Практика: PBVI, SARSOP, онлайн-планировщики POMCP и DESPOT
- Для группы — Dec-POMDP, сложность ещё выше; спасают иерархии

Выводы

- 1 Состояние робота — распределение, а не число; байесовский фильтр обновляет его рекурсивно
- 2 KF и EKF дают дешёвое гауссовское приближение, фильтр частиц — многомодальность и глобальную локализацию
- 3 SLAM решает задачу «курица и яйцо»; современный стандарт — графовая оптимизация
- 4 Мультиробот-SLAM добавляет межроботную ассоциацию, ложные совпадения мест и дефицит связи
- 5 Распределённая оптимизация графа поз — прямое приложение схемы «расщепление плюс консенсус»
- 6 Отбраковка выбросов обязательна до оптимизации: одно ложное ребро рушит карту группы
- 7 Планирование и избегание столкновений строятся иерархией: глобальный слой плюс быстрый локальный

Вопросы для самопроверки

1. Почему интегрирование данных IMU даёт неограниченный рост ошибки, а лидар — нет?
2. Запишите шаги прогноза и коррекции байесовского фильтра и поясните смысл каждого
3. Как ведёт себя усиление Калмана при $R \rightarrow 0$ и при $R \rightarrow \infty$?
4. Чем ограничена линеаризация в EKF и когда предпочтителен фильтр частиц?
5. Почему в SLAM ошибки позы и карты коррелированы и что даёт замыкание цикла?
6. Сравните EKF-SLAM, графовый SLAM и FastSLAM по сложности и робастности
7. Что такое «инцест данных» и как его лечит ковариационное пересечение?
8. Чем межроботная ассоциация данных сложнее внутрироботной?
9. Почему отбраковка выбросов выполняется до распределённой оптимизации, а не после?
10. За счёт чего ORCA устраняет осцилляции и сводит выбор скорости к задаче ЛП?