

Лекция 16. Безопасность взаимодействия в распределённых робототехнических системах

Функциональная и информационная безопасность: стандарты, защитные дистанции, византийские отказы

90 минут · две части по 45

Курс «Управление распределёнными робототехническими системами»

План лекции

- 1 Два измерения безопасности: safety и security
- 2 Очувствление как основа защитных функций
- 3 Нормативная база: ISO 10218:2025, 15066, 13482, 3691-4
- 4 Оценка риска по ISO 12100; уровни PL и SIL
- 5 Зоны, защитная дистанция, барьерные функции

- 6 Отказоустойчивость и постепенная деградация группы
- 7 Модель угроз информационной безопасности
- 8 Защита коммуникаций: DDS Security и SROS2
- 9 Византийские отказы, $n \geq 3f + 1$, алгоритм W-MSR
- 10 Доверие, репутация и физика радиоканала

Синие — первая часть · янтарные — вторая часть

Часть 1. Функциональная безопасность

Как система не причиняет вреда при штатной работе, при отказах и при неправильном применении

Функциональная (safety)

- Не вредить при штатной работе и отказах
- Сенсорика, избегание столкновений
- Ограничение сил и скоростей
- Отказоустойчивая архитектура
- Регламентируется стандартами ISO

Информационная (security)

- Защита от преднамеренных воздействий
- Перехват и подмена данных
- Компрометация агентов изнутри
- Атаки на связь и координацию
- Криптография + устойчивые алгоритмы

“

Нет safety без security: скомпрометированный робот — это не строка в базе данных, а масса, скорость и энергия

Поэтому анализ рисков физического вреда обязан включать сценарии преднамеренного вмешательства

- Цепочка: обнаружение опасного события → решение → защитная реакция
- Сенсор обнаруживает: человек в зоне, контакт, потеря сцепления
- Логика решает, исполнительный уровень тормозит или отводит звено
- Датчики защитных функций сами должны быть надёжны
- Средства: самодиагностика, дублирование, перекрёстная проверка

Ключевая идея

Никакой алгоритм безопасности не может быть лучше данных, на которых он основан. Отказ датчика не должен приводить к необнаруженной потере защитной функции — это требование, а не пожелание.

- Две задачи: обнаружить непредвиденный контакт и ограничить усилие
- Столкновение — скачок силы или расхождение с модельным моментом
- Тензометрия: изменение сопротивления упругого элемента при деформации
- Пьезоэлектрика: заряд при механическом нагружении, высокая полоса
- Бессенсорное обнаружение по токам двигателей и наблюдателю момента

Факт

Бессенсорное детектирование контакта дешевле на порядок, но требует точной динамической модели: любая неучтённая нагрузка на фланце выглядит как столкновение — и робот останавливается на пустом месте.

- Ультразвук: дёшево, независимо от света, но широкая диаграмма и малая дальность
- ИК: ближняя зона, обнаружение краёв и перепадов высоты
- Лидары: облака точек; сертифицированные сканеры задают защитные поля
- Радар мм-диапазона: работает в пыли, тумане, осадках
- Зрение: RGB, RGB-D, стерео — распознавание людей и прогноз движения
- Слабости зрения: свет, вычисления, состязательные искажения

Одиночный канал

- Отказ = потеря защитной функции
- Известны условия обмана канала
- Слепые зоны никем не перекрыты
- Дёшево и просто в интеграции

Слияние разнородных данных

- Расхождение каналов = сигнал тревоги
- Обмануть надо все каналы сразу
- Физика разная: свет, звук, радио, сила
- Дороже, сложнее синхронизация

- ISO 10218-1 — требования к роботу, ISO 10218-2 — к ячейке и интеграции
- **Действует редакция 2025 года**, она заменила версию 2011 года
- Учебники и старые проекты всё ещё цитируют 2011 — проверяйте год
- ISO/TS 15066 — биомеханические пределы и расчёт защитной дистанции
- «Коллаборативным» является приложение, а не сам робот

Ключевая идея

Один и тот же манипулятор безопасен, когда переносит поролон, и опасен, когда держит фрезу. Сертификат на робота никогда не заменяет оценку риска конкретного приложения.

Аспект	Редакция 2011	Редакция 2025
Классификация	Единые требования ко всем	Два класса роботов
Уровень PL	По умолчанию PL d, кат. 3	PL для каждой функции по оценке риска
Мобильные платформы	Практически не охвачены	Явная отсылка к ISO 3691-4
Коллаборация	Отдельный ISO/TS 15066	Требования подтянуты в основной текст
Кибербезопасность	Не рассматривалась	Признана частью безопасности

Главный сдвиг: от фиксированного уровня к обоснованию уровня расчётом риска


Метод	Что происходит	Ключевой параметр
Контролируемый останов	Робот стоит, питание сохранено	Время до останова
Ручное ведение	Оператор ведёт робот рукой	Усилие на рукоятке
Скорость и дистанция	Робот замедляется при сближении	Дистанция S
Ограничение мощности и силы	Контакт допустим, но слабый	Пороги давления и силы

Последние два детализирует ISO/TS 15066: пределы боли и формула защитной дистанции

- ISO 13482 — персональные и сервисные роботы, роботы физической поддержки
- Жилая среда: дети, пожилые, животные, необученный пользователь
- Требования: устойчивость к опрокидыванию, безопасность при отказе питания
- **ISO 3691-4:2023** — безрельсовые напольные транспортные средства, то есть AGV и AMR
- Именно 3691-4 задаёт защитные поля, скорости и торможение складских тележек

Кейс

Мобильный манипулятор — это одновременно робот по ISO 10218 и тележка по ISO 3691-4. Редакция 2025 года прямо это признаёт и отсылает к 3691-4 в части ходовой базы.



Процесс итеративный: каждая мера снижения риска сама порождает новые опасности

$10^{-7} \dots 10^{-6}$

SIL 2: опасных отказов в час
(МЭК 61508)

$10^{-8} \dots 10^{-7}$

SIL 3: на порядок строже

PL d $\approx$ SIL 2

соответствие шкал; PL e $\approx$ SIL 3

2 канала

категория 3: одиночный отказ
не теряет функцию

- PL по ISO 13849-1 определяют категория, наработка на отказ и диагностика
- Требуемый PL для каждой функции обосновывается оценкой риска
- Каналы безопасности отделяются от «несейфового» контура планирования

- Вложенные зоны с нарастающей строгостью реакции вокруг источника опасности
- Предупредительная — сигнализация; средняя — пониженная скорость
- Защитная — защитный останов при вторжении
- Реализация: лазерные сканеры, световые барьеры, коврики давления
- Динамика: конфигурация полей переключается по скорости и фазе цикла
- Для мобильных роботов поле вытягивается по вектору скорости

5 Минимальная защитная дистанция (ISO/TS 15066)

$$S = v_h \cdot (t_r + t_s) + v_r \cdot t_r + B + C + Z_h + Z_r$$

- v_h — скорость человека, норматив 1,6 м/с; v_r — скорость робота
- t_r — время реакции системы; t_s — время останова; B — тормозной путь
- C — добавка на проникновение части тела до срабатывания датчика
- Z_h, Z_r — погрешности определения положения человека и робота

Смысл прост: за время реакции и торможения человек и робот сближаются — дистанция обязана это покрыть


Из чего складывается защитная дистанция

Из чего складывается защитная дистанция (ISO/TS 15066)

человек



робот



S_p — минимальная защитная дистанция

T_r — время реакции системы, T_s — время срабатывания останова, B — тормозной путь,
 C — неопределённость положения человека, Z_d и Z_r — погрешности датчика и системы управления.

Слагаемые S_p : путь человека $v_h \cdot (T_r + T_s)$, путь робота $v_r \cdot T_r$, тормозной путь B и погрешности $C + Z_d + Z_r$

Разобраный пример: получаем 1,30 м

- Дано: $v_r = 0,5 \text{ м/с}$; $t_r = 0,2 \text{ с}$; $t_s = 0,3 \text{ с}$; $B = 0,08 \text{ м}$; $C = 0,2 \text{ м}$; $Z = 0,12 \text{ м}$
- Путь человека: $1,6 \cdot (0,2 + 0,3) = 0,80 \text{ м}$ — больше половины всей дистанции
- Путь робота за время реакции: $0,5 \cdot 0,2 = 0,10 \text{ м}$
- $S = 0,80 + 0,10 + 0,08 + 0,20 + 0,12 = \mathbf{1,30 \text{ м}}$
- Доступно лишь 0,9 м? Снижаем скорость: при $v_r = 0,2 \text{ м/с}$ получим $S \approx 1,1 \text{ м}$

Пример

Типичный инженерный компромисс: скорость робота против компактности планировки участка. Часто дешевле переставить стеллаж, чем весь год работать на половинной производительности.



Как думаете?

Дистанцию 1,30 м нужно уменьшить. Какой параметр даст наибольший выигрыш?

А

Уменьшить тормозной путь B , поставив мощные тормоза

В

Уменьшить время реакции t_r системы обнаружения

С

Уменьшить погрешности сканера Z_h и Z_r

Д

Уменьшить конструктивную добавку C

? Как думаете?

Дистанцию 1,30 м нужно уменьшить. Какой параметр даст наибольший выигрыш?

A Уменьшить тормозной путь B , поставив мощные тормоза

B Уменьшить время реакции t_r системы обнаружения

C Уменьшить погрешности сканера Z_h и Z_r

D Уменьшить конструктивную добавку C

ОТВЕТ

Время реакции t_r : оно входит в формулу с множителем $(v_h + v_r) = 2,1$ м/с, то есть каждые 0,1 с реакции стоят более 20 см дистанции.

Управляющие барьерные функции (CBF)

$$\dot{h}(x, u) \geq -\alpha(h(x)), \quad h(x) \geq 0 \text{ — безопасно}$$

- $h(x)$ — например, квадрат расстояния до препятствия минус допустимый минимум
- α — возрастающая функция, равная нулю в нуле
- Чем ближе граница, тем медленнее разрешено к ней приближаться
- Реализация: квадратичное программирование на каждом такте — «безопасный фильтр»

Зона — дискретное переключение режимов; CBF встраивает безопасность в сам закон управления

- FMEA: виды отказов × последствия; приоритет = тяжесть × вероятность × обнаружение
- Аппаратное: двухканальные цепи, троирование с голосованием два из трёх
- Информационное: контрольные суммы, сверка одометрии, лидара и ГНСС
- Функциональное: отказал лидар — медленно едем по камерам и бамперам
- Против отказов по общей причине — разные платформы и независимое ПО

Факт

Резервирование работает только против независимых отказов. Общее питание, общая программная ошибка или общая уязвимость обнуляют любую кратность резерва — три одинаковых канала падают синхронно.

7

Постепенная деградация группы роботов



Graceful degradation: производительность падает плавно, безопасность сохраняется до контролируемой остановки

Конец первой части

*Разобрали safety: сенсорику, стандарты, дистанции, барьерные функции и деградацию.
После перерыва — security: кто и как атакует РРТС и что с этим делать*

Часть 2. Информационная безопасность

Угрозы, криптография каналов, SROS2 и алгоритмы, работающие даже при предателях внутри группы

- Наследуют уязвимости трёх миров сразу
- Беспроводные сети: открытая среда передачи, любой может слушать
- Киберфизические системы: управление физикой в реальном времени
- Распределённые вычисления: нет единой доверенной точки
- Поверхность атаки: радиоканалы, сенсоры, ПО, поставка, сервисные интерфейсы

Ключевая идея

Последствия атаки на RPTC материальны и необратимы. Откат транзакции в базе возможен, откат наезда на человека — нет. Поэтому здесь недопустима логика «переживём инцидент и починим».

Угроза	Нарушается	Контрмеры
Перехват (eavesdropping)	Конфиденциальность	Шифрование, минимизация данных
Подмена ГНСС (spoofing)	Целостность навигации	Мультисистемность, сверка с одометрией
Обман сенсоров	Целостность восприятия	Слияние датчиков, проверка правдоподобия
MITM и повтор (replay)	Целостность, актуальность	Аутентификация, подписи, nonce, метки
Компрометация агента	Целостность поведения	Византийский консенсус, репутация
DoS и глушение	Доступность	Резервные каналы, безопасные режимы
Sybil-атака	Целостность членства	Криптографическая идентификация

Внешний нарушитель без ключей парируется криптографией; внутренний с ключами — только алгоритмами

- GNSS-spoofing: поддельные сигналы плавно уводят оценку координат
- Плавность — главная опасность: скачок замечен, дрейф в 10 см/с нет
- Обман лидара: подсветка импульсами создаёт ложные или скрывает реальные точки
- Состязательные образы: наклейка на знаке меняет класс объекта у нейросети
- Защита: сверка разнородных каналов и проверка физической правдоподобности

Кейс

Проверка правдоподобия — самая дешёвая контрмера: если по ГНСС платформа сместилась на 3 м за секунду, а колёсная одометрия и ИНС говорят о 0,5 м, доверять нужно физике, а не радио.



Проверим понимание

Злоумышленник физически захватил одного робота парка вместе с его ключами и сертификатом. Что поможет?

A

Включить шифрование всех тем — трафик станет нечитаемым

B

Усилить взаимную аутентификацию по сертификатам X.509

C

Византийски устойчивый консенсус и система репутации

D

Перейти на более длинные ключи и сменить алгоритм подписи



Проверим понимание

Злоумышленник физически захватил одного робота парка вместе с его ключами и сертификатом. Что поможет?

A

Включить шифрование всех тем — трафик станет нечитаемым

B

Усилить взаимную аутентификацию по сертификатам X.509

C

Византийски устойчивый консенсус и система репутации

D

Перейти на более длинные ключи и сменить алгоритм подписи

ОТВЕТ

Только третье. Захваченный агент — легитимный участник: он аутентифицируется, подписывает и расшифровывает. Спасают лишь алгоритмы, терпящие ложь изнутри.

- Конфиденциальность — AES в режимах аутентифицированного шифрования
- Целостность и подлинность — HMAC при симметрии, ECDSA или RSA при асимметрии
- PKI: сертификат каждого робота, взаимная аутентификация, сеансовый ключ
- Защита от повтора — счётчики и метки времени, нужна синхронизация часов
- Эллиптические кривые: короткие ключи для встраиваемых платформ
- TPM и secure element хранят ключи вне доступа прикладного ПО

- ROS 2 работает поверх DDS: публикация и подписка без центрального брокера
- Аутентификация участников — взаимная проверка сертификатов X.509
- Управление доступом — подписанные разрешения: кто что публикует и читает
- Криптография — шифрование и аутентификация данных и служебного трафика
- Журналирование событий безопасности и маркировка данных
- **Без защиты любой узел в сети читает темы и публикует команды**

Факт

Незащищённый ROS 2 обнаруживает соседей мультикастом и принимает команды от кого угодно. Ноутбук, подключённый к той же сети, способен опубликовать `/cmd_vel` и увести платформу.



Анклав — это область в хранилище, задающая идентичность и права набора узлов

- Криптография не отменяет сетевой гигиены — это два независимых слоя
- Отдельный VLAN или SSID для роботов, отдельный — для офиса и гостей
- Контур безопасности изолирован от внешних сетей физически, а не правилом
- Обновления по воздуху — только подписанные образы через защищённый канал
- Принцип наименьших привилегий: телеметрия наружу, команды только внутрь

Ключевая идея

Сегментация ограничивает не вероятность взлома, а его радиус поражения. Компрометация панели оператора не должна давать доступ к шине управления приводами.



- Против глушения криптография бессильна: подавляется и шифрованный трафик
- Физический уровень: расширение спектра, скачкообразная перестройка частоты
- Дублирование каналов разной природы: Wi-Fi и LTE/5G, радио и оптика
- Ячеистые сети с многопутевой маршрутизацией
- Главное — локальная автономия и заранее заданный режим при потере сети

Ключевая идея

Потеря связи в правильно спроектированной RPTC снижает производительность, но никогда не порождает опасного поведения. Это проектное требование, проверяемое испытанием.

- Лэмпорт, Шостак, Пиз, 1982: согласие при предателях, лгущих по-разному
- Византийский отказ — самый общий: произвольное и скоординированное поведение
- Без подписей согласие достижимо тогда и только тогда, когда $n \geq 3f + 1$
- Один предатель — минимум 4 агента, два предателя — минимум 7
- С подписями достаточно $n \geq f + 2$, но ложь легитимным ключом остаётся

Условие византийской отказоустойчивости: $n \geq 3f + 1$
 $n = 3, f = 1$ консенсус НЕДОСТИЖИМ
 $n = 4, f = 1$ консенсус ДОСТИЖИМ



Красный узел — византийский агент, посылающий разным соседям противоречивую информацию.
При $n = 3$ и одном предателе честные узлы не могут отличить, кто лжёт. При $n = 4$ — уже могут.

Слева три узла с одним предателем — консенсус недостижим; справа четыре узла — достижим. Порог $n \geq 3f + 1$

- А, В, С честные, D скомпрометирован; решают: продолжать работу или эвакуироваться
- Раунд 1: А, В, С шлют «продолжать»; D шлёт А «продолжать», а В и С «эвакуироваться»
- Раунд 2: каждый пересылает остальным то, что услышал в первом раунде
- По источникам А, В, С свидетельства совпадают — одиночная ложь D тонет
- По источнику D у всех честных большинство даёт «эвакуироваться»
- Векторы честных идентичны, общее решение по большинству — «продолжать»

Пример

Обратите внимание: честные агенты не выяснили, кто именно предатель. Они лишь пришли к одинаковому вектору свидетельств — а этого достаточно для единого решения.

$$x_i(t + 1) = w_{ii} \cdot x_i(t) + \sum_j w_{ij} \cdot x_j(t)$$

- Перед усреднением агент отбрасывает F наибольших и F наименьших значений соседей
- Суммирование ведётся только по оставшимся соседям j , веса положительны, сумма равна 1
- Локальность: не нужны ни идентификация лжецов, ни глобальная информация
- Бонус: отбрасывание крайних значений защищает и от обычных сбоев датчиков

Полные протоколы византийского согласия требуют обменов «все со всеми» — W-MSR обходится соседями

- Сходимость W-MSR при F византийских соседях требует $(2F+1)$ -робастности графа
- Робастность: у любых двух непересекающихся множеств есть узлы с $2F+1$ соседями снаружи
- **r-робастность влечёт r-связность, но обратное неверно**
- Цепочка и дерево связны и беззащитны: единственный лжец-посредник рвёт согласие
- Устойчивость покупается избыточностью связей, а не просто наличием пути

Ключевая идея

Топология сети становится параметром безопасности. Проектируя рой, вы задаёте не только дальность связи, но и то, сколько предателей группа переживёт без потери согласия.

Из чего строится доверие

- Согласуются ли сообщения с моими измерениями
- Выполняет ли сосед взятые обязательства
- Правдоподобны ли данные физически
- Репутация как вес в слиянии и голосовании
- Ниже порога — изоляция и отзыв ключей

Атаки на саму репутацию

- Клевета: сговор против честного узла
- Самовосхваление и накрутка оценок
- Отмывание: возврат под новым именем
- Медленное предательство после доверия
- Ответ: криптопривязка идентичности

- Криптография отвечает «у него правильный ключ», но не «он тот, за кого себя выдаёт»
- Статистика беспроводного сигнала (RSSI, характеристики канала) выдаёт источник
- Робот измеряет, откуда физически пришли сообщения соседа при своём движении
- Sybil-атака рушится: десять идентичностей из одной точки видны по профилю сигнала
- Критично при физическом захвате робота: ключи украдены, физику подделать труднее

Ключевая идея

Физический уровень даёт независимый от криптографии канал доверия. Комбинация «ключи + физика радиоканала» закрывает именно тот случай, где криптография бессильна.

- Реплицируемый неизменяемый журнал событий и «умные контракты»
- Штробель, Кастельо Феррер, Дориго: рой принимает верные решения при византийцах
- Вредитель либо не навяжет ложь, либо экономически теряет внесённый залог
- Плюсы: неотказуемость действий, координация без доверенного центра
- Минусы: издержки консенсуса, задержки подтверждения, энергопотребление

“

Безопасность многослойна: ни один механизм не достаточен в одиночку, работает только согласованная комбинация

Конструкция + алгоритмы + криптография + организационные меры = приемлемый остаточный риск

Выводы

- 1 Safety и security неразрывны: атака на управление немедленно становится физической угрозой
- 2 Цепочка safety: разнородная сенсорика — зоны и дистанция — CBF — смягчение контакта
- 3 Нормы обновились: действует ISO 10218:2025, для AGV и AMR — ISO 3691-4:2023
- 4 PL теперь обосновывается для каждой функции безопасности по оценке риска
- 5 Отказоустойчивость: FMEA, разнородный резерв, постепенная деградация группы
- 6 Внешние угрозы — криптография каналов, DDS Security и SROS2, сегментация сети
- 7 Внутренние — $n \geq 3f + 1$, W-MSR на r -робастном графе, репутация и физика радиоканала

Вопросы для самопроверки

1. В чём различие safety и security и почему их нельзя рассматривать порознь?
2. Как разнородная избыточность одновременно повышает надёжность и стойкость к обману?
3. Что изменилось в ISO 10218 в редакции 2025 года по сравнению с 2011-й?
4. Какой стандарт профильный для AGV и AMR и что он регламентирует?
5. Опишите шаги оценки риска по ISO 12100 и порядок трёхшагового снижения
6. Запишите формулу дистанции S и укажите самый чувствительный параметр
7. В чём идея CBF и почему «безопасный фильтр» сочетается с обучаемым планировщиком
8. Какие пять модулей вводит DDS Security и что даёт SROS2 на практике?
9. Объясните порог $n \geq 3f + 1$ и почему подписи не спасают от захваченного агента
10. Опишите шаг W-MSR. Почему g -робастность не то же самое, что g -связность?